

Gaze estimation at lowest edge devices:

시스템 구조와 경량화 설계

대림대학교 박제형 김영우 김영범 이민혁

2025년 11월 6일

요약

웹캠 기반 시선/입모양 인터페이스의 핵심 알고리즘을 간결히 정리한다. 경량 시선 추정(MPIIGaze, $\sim 7.7 \times 10^4$ params), 초소형 입 회귀($< 10^3$ params), 4점 투시변환 기반 좌표 매핑, 2D 칼만 필터 안정화를 결합해 **단일 칩(MCU)** 엣지 환경에서도 실시간·저전력 동작을 달성한다.

1 서론

배경 기존 상용 시선 추적 시스템은 높은 도입 비용과 과도한 전력 소모라는 분명한 장벽이 존재한다. 또한 클라우드 기반 처리는 네트워크 왕복 지연으로 반응성이 떨어지고, 개인 생체 정보를 외부로 전송해야 하는 *프라이버시* 우려를 야기하여 일상적인 기기 적용에 제약이 크다.

목표 본 연구의 목표는 다음과 같다.

- **저전력·저비용:** 고가의 외부 장치 없이, 상용 웹캠과 **단일 칩(MCU)**만으로 시선 인터페이스 구현
- **저전력 MCU급 엣지 AI:** 라즈베리파이·쥬얼 등 고성능 AP에 의존하지 않고, **MCU급 프로세서와 경량 NPU/AI 가속기**에서 동작 가능한 **온디바이스(On-Device)** 추론 설계(예: STM32N6-class)
- **즉각적 반응성·프라이버시:** 네트워크 지연 요인을 원천 제거하고, 사용자 데이터를 디바이스 외부로 전송하지 않음
- **최종 목표:** 고성능 시선 인터페이스의 **대중화**를 앞당기고, **보조공학·스마트홈** 등 다양한 분야에서 사용 편의성을 극대화

범위와 현재 상태 본 문서는 **MCU급 타깃을 고려한 개념 설계**를 제시한다. 아직 MCU 내 실장용 모델 **최적화**(양자화, 가지치기, 커널 융합 등)와 **저전력 처리 파이프라인**(입 출력 파이프라이닝, RTOS 스케줄링, 메모리 풋프린트 관리 등)은 구현 전 단계이며, 향후 작업으로 남겨둔다.

Face Mesh(468점, $\sim 3.5\text{M}$ params)는 정확도와 강인성이 뛰어나지만, **MCU급** 타깃에는 여전히 무겁다. 따라서 BlazeFace(검출) + 소형 **랜드마크 회귀 헤드**(예: 눈/입/코 등 필수 소수 점 또는 68점 계열, $\lesssim 300\text{k}$ params)로 대체가 필요하다.

이 목표를 달성하기 위해, 본 문서는 경량 시선 추정과 초소형 입 회귀, 투시변환 기반 좌표 매핑, 2D 칼만 필터를 조합한 **엣지 온디바이스 파이프라인**을 제시한다.

2 시스템 개요




그림 1: 시스템 개요 파이프라인: 랜드마크/머리자세→시선/입 회귀→UDP TX/RX→투영/호모그래피/칼만→커서/명령

구성 및 역할 시스템은 **서버(송신/추론)**와 **클라이언트(수신/보정/제어)**로 나뉜다. 서버는 카메라 프레임에서 얼굴 랜드마크와 머리자세를 추정해 시선 및 입 모양 지표를 계산하고, 이를 *UDP*로 지속 송신한다. 클라이언트는 수신값을 사용자 캘리브레이션(투시변환)과 칼만 필터로 보정해 화면 좌표/명령으로 변환한다. 얼굴 랜드마크는 MediaPipe Face Mesh([7, 6])를 사용한다.

- **서버(UDP 송신):** 프레임 캡처 및 왜곡 보정 → 랜드마크/머리자세(EPnP [8]) → 정규화 → 시선 추정(모드: MPIIGaze/MPIIFaceGaze/ETH-XGaze) → 입 회귀 → 패킷화 및 전송. 신규 클라이언트의 바인딩 요청을 수락해 리스트에 등록하고 동일 페이로드를 브로드캐스트 형태로 송신한다.
- **클라이언트(보정/제어):** 패킷 수신 → 시선 2D 투영 → 호모그래피 H 적용(화면 좌표화) → 2D 칼만 보정(지터 억제) → 커서 위치/명령 출력. 입벌림/입술위치를 이용해 클릭·스크롤 등 모달 명령을 생성한다.

전체 파이프라인은 그림 1와 같이 **서버(좌)**와 **클라이언트(우)**로 구분되며, UDP TX/RX를 통해 연동된다.

분할 이유(개발 · 테스트 용이성) 서버/클라이언트 분리는 **빠른 반복 개발**과 **재현 가능한 테스트**를 위해 의도적으로 도입하였다. 예를 들어, 추론부만 엣지(MCU/NPU)로 이전하고 전처리 · 보정 · UI는 호스트에서 유지하는 **하이브리드 구성**을 손쉽게 실험할 수 있다.

3 모델 구조

3.1 MPIIGaze: Pre-activation ResNet-8 + Head Pose 결합

모델은 얇은 ResNet(깊이 8, 기본 채널 16)과 2차원 정규화 머리자세를 결합하여 2D 시선 각(피치/요)을 회귀한다. 입력은 단안 눈 패치($1 \times 36 \times 60$), 우안의 경우 수평 반전 및 자세 부호 보정을 수행한다.

관련 선행 연구로는 모바일/웹캠 환경의 appearance-based 시선 추정을 다룬 [2, 3, 4, 5] 등이 있다.

참고 본 MPIIGaze 설계와 구현은 Zhang et al. [1]의 방법과 공개 자료를 전반적으로 참고한다. 모델의 블록도는 그림 2에 제시하였다.




그림 2: MPIIGaze 상세: Pre-activation ResNet-8 특징(64) + 정규화 머리자세(2) 결합 $\rightarrow$ FC(66 $\rightarrow$ 2) $\rightarrow$ 시선 각 회귀

파라미터 수 각 합성곱은 `bias=False`, 배치정규화는 `scale/bias`만 학습하며, GAP 이후 FC 입력 차원은 $64+2=66$ 이다. 대략적 파라미터 총량은

$$\underbrace{\sim 7.7 \times 10^4}_{\text{Conv/BN 전체}} + \underbrace{132}_{\text{FC 가중치}} + \underbrace{2}_{\text{FC bias}} \approx 7.7 \times 10^4.$$

즉, 약 **77k** 수준으로 매우 작다(엣지 배포에 유리).

3.2 Mouth Regressor: 초소형 Two-head MLP

입 특징은 기하적 상관이 강하고 저차원 관계가 지배적이므로 폭 4의 얇은 MLP와 두 개의 1D 헤드로 충분하다. 전처리 표준화로 학습을 단순화하고, Select-up으로 입력 차원을 상위 k 로 축소해 추론 경로는 선형→활성→선형 두 단계만 거치므로 MCU/NPU에서 지연과 전력 소모를 크게 줄인다.

모듈 개요는 그림 3에 도시하였다.




그림 3: 입 회귀 모듈: 선택·정규화된 랜드마크를 표준화 후, 얇은 MLP(hidden=4)와 두 헤드(*openness*, *lip position*)로 회귀

MouthRegressor는 하나의 얇은 은닉층(예: hidden=4) 뒤에 *openness*(sigmoid), *lip position*(tanh) 두 개의 1차원 헤드를 둔다. 입력은 정규화 랜드마크를 평탄화하고, 전처리에서 스케일링(`mean/std`)을 적용한다.

파라미터 수 입력 차원을 n 이라 할 때, 파라미터는 대략 $4n + 14$ 개(은닉 4의 가중치+바이어스, 두 헤드의 가중치+바이어스 포함). 예컨대, 특징 200개 내외($n \approx 200$)면 $\sim 8 \times 10^2$ 로 1천 미만이다.

Select-up(특징 선택): L1 스파스 로지스틱 기반

입 회귀의 입력 차원을 최소화하기 위해, 라벨 분류용 선형 모델(다항 로지스틱 회귀)에 L_1 패널티를 주어 가중치를 희소화하고, *가중치 절대값 평균*으로 중요도를 산출해 상위 k 개의 랜드마크 좌표를 선택한다. 전처리/선택 파이프라인은 아래와 같다.

수식 정식화 데이터 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ 에서 입력 $x_i \in \mathbb{R}^n$, 클래스 $y_i \in \{1, \dots, C\}$ 에 대해, 클래스별 로짓 $z_c = w_c^T x + b_c$ 와 소프트맥스 확률

$$p(y = c \mid x; W, b) = \frac{\exp(w_c^T x + b_c)}{\sum_{k=1}^C \exp(w_k^T x + b_k)} \quad (1)$$

을 정의한다. 이는 LASSO 유형의 L_1 정규화 분류 설정으로 좌표강화 기반의 해법이 널리 쓰인다([11, 12]). 다항 로지스틱의 평균 음의 로그우도(교차엔트로피)와 L_1 정규화 항을 합한 목적함수는

$$\mathcal{J}(W, b) = \frac{1}{N} \sum_{i=1}^N \left[-\log p(y_i \mid x_i; W, b) \right] + \lambda \|W\|_1, \quad (2)$$

$$\|W\|_1 = \sum_{c=1}^C \sum_{j=1}^n |W_{cj}|. \quad (3)$$

L_1 패널티는 계수의 희소성을 유도하여 불필요한 특징을 억제한다. 학습된 가중치로부터 특징 중요도는

$$s_j = \frac{1}{C} \sum_{c=1}^C |W_{cj}|, \quad j = 1, \dots, n \quad (4)$$

과 같이 정의하고, s_j 상위 k 개의 인덱스를 선택한다.

선택 파이프라인의 흐름은 그림 4에 나타났다.




그림 4: 입 회귀 Select-up(특징 선택) 파이프라인: 표준화 → 스파스 선형 학습(L_1) → 중요도 산출 → 상위 k 좌표 선택 → 축소 입력 생성.

학습 데이터 및 성능

교내 환경에서 **학생 13명(임의 선택)**을 대상으로 소규모 데이터셋을 수집하여 MouthRegressor를 학습하였다. Select-up으로 상위 k 특징만 사용하고 표준화를 적용했을 때, 총 파라미터 수가 $< 10^3$ 인 얇은 MLP가 입벌림(openness)과 입술 위치(lip position)에 대해 **소량 수집한 데이터로도 안정적으로 동작함**을 관찰하였다. 클래스별 전체 합계: *mouth_closed* 1707, *mouth_open* 1557, *lip_raise* 1231, *lip_lower* 1627.

4 사용자 캘리브레이션과 좌표 매핑

4.1 시선 3D→2D 투영 벡터

핀홀 모델 기반의 단순 투영은 스크린 평면 상 단조 매핑을 제공해 이후 호모그래피 보정과 잘 결합된다. 3D 레이-플레인 교차를 명시적으로 계산하는 것과 동치이면서도 연산이 매우 가볍고, 정규화된 머리자세·눈 패치 가정하에 잡음에 덜 민감하다([9]).

양안의 정규화 시선 벡터 $v_i = (x_i, y_i, z_i)$ 를 합해 $r = \sum_i v_i$ 라 하고, 2D 투영 벡터 $p \in \mathbb{R}^2$ 는

$$p = \begin{bmatrix} r_x/(-r_z) \\ r_y/(-r_z) \end{bmatrix}, \quad (r_z \neq 0). \quad (5)$$

우안의 수평 성분은 데이터 정합을 위해 부호 반전한다.

4.2 이상치 제거(IQR)와 대표점

각 화면 타겟(네 모서리)을 일정 시간 응시하며 $\{p_t\}_{t=1}^N$ (각 $p_t \in \mathbb{R}^2$)를 수집한 뒤, **중심점과의 거리 분포**에서 IQR 기반 문턱으로 이상치를 제거하고, 남은 샘플의 평균을 대표점으로 정의한다([10]).

한 타겟에 대해 먼저 임시 중심을

$$\bar{p} = \frac{1}{N} \sum_{t=1}^N p_t \in \mathbb{R}^2 \quad (6)$$

로 두고, 각 샘플의 중심까지의 유클리드 거리를

$$d_t = \|p_t - \bar{p}\|_2, \quad t = 1, \dots, N \quad (7)$$

로 정의한다. 거리 집합 $\{d_t\}$ 의 제1사분위수와 제3사분위수를 각각

$$Q_1 = \text{quantile}_{0.25}(\{d_t\}), \quad Q_3 = \text{quantile}_{0.75}(\{d_t\}) \quad (8)$$

로 두면, 사분위 범위(IQR)와 상/하한 펜스는

$$\text{IQR} = Q_3 - Q_1, \quad (9)$$

$$F_L = \max(0, Q_1 - 1.5 \text{IQR}), \quad F_U = Q_3 + 1.5 \text{IQR} \quad (10)$$

으로 준다. (거리 $d_t \geq 0$ 이므로 실무에선 상한 F_U 만으로도 충분하다.) 이때 inlier 집합과 대표점은

$$\mathcal{I} = \{t \in \{1, \dots, N\} : F_L \leq d_t \leq F_U\}, \quad (11)$$

$$\hat{p} = \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} p_t \quad (12)$$

으로 정의한다. 네 모서리 각각에 대해 위 절차를 적용하여 $\{\hat{p}_j\}_{j=1}^4$ 를 얻고, 이후 호모그래피 추정에 사용한다.

4.3 투시변환

네 점만으로 평면 사상 H 를 추정하면 학습기나 비선형 최적화를 도입하지 않고도 사용자별·환경별 보정이 가능하다.

시선 평면 상의 대표 4점 $\{\bar{p}_j\}$ 과 화면의 대응 4점 $\{p'_j\}$ 를 이용해, 동차좌표에서

$$\lambda \begin{bmatrix} p'_x \\ p'_y \\ 1 \end{bmatrix} = H \begin{bmatrix} \bar{p}_x \\ \bar{p}_y \\ 1 \end{bmatrix}, \quad H \in \mathbb{R}^{3 \times 3}, \lambda \neq 0. \quad (13)$$

OpenCV의 `getPerspectiveTransform`으로 H 를 추정하고, 실시간 벡터 $\bar{p}$ 에 `perspectiveTransform`을 적용하여 화면 좌표 p' 를 얻는다([9]).

5 칼만 필터 기반 안정화

5.1 상태/측정 모델

2D 위치/속도 상태 벡터 $x = [p_x, p_y, v_x, v_y]^T$ 와 측정 $z = [p_x, p_y]^T$ 를 사용한다. 시간 간격 dt 에서

$$x_{k|k-1} = A(dt) x_{k-1|k-1}, \quad A(dt) = \begin{bmatrix} 1 & 0 & dt & 0 \\ 0 & 1 & 0 & dt \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad (14)$$

$$z_k = H x_{k|k-1} + \text{noise}, \quad H = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}. \quad (15)$$

프로세스 잡음 Q 와 측정 잡음 R 은 대각 공분산으로 두며, R 은 캘리브레이션 수집치의 분산으로 추정(스케일 조절)한다.

5.2 예측/보정

상수 속도(2D) 상태공간 모델은 파라미터가 적고 튜닝이 단순하며, 가변 dt 를 행렬 $A(dt)$ 에 반영해 프레임 변동에도 안정적이다. 공분산 Q, R 을 대각으로 두어 연산량을 최소화하고, 역행렬도 2×2 로 닫힌형이라 임베디드에서 계산 부담이 작다.

표준 칼만 필터 갱신을 따른다([13, 14]):

$$\text{Predict:} \quad x_{k|k-1} = A x_{k-1|k-1}, \quad P_{k|k-1} = A P_{k-1|k-1} A^T + Q, \quad (16)$$

$$\text{Update:} \quad y_k = z_k - H x_{k|k-1}, \quad S_k = H P_{k|k-1} H^T + R, \quad (17)$$

$$K_k = P_{k|k-1} H^T S_k^{-1}, \quad (18)$$

$$x_{k|k} = x_{k|k-1} + K_k y_k, \quad P_{k|k} = (I - K_k H) P_{k|k-1}. \quad (19)$$

여기서 y_k 는 잔차이다. 본 시스템에서는 `correct(z, dt)` 인터페이스로 예측과 보정을 한 번에 수행한다.

6 엣지 배포 적합성

- **모델 크기:** MPIIGaze $\approx 7.7 \times 10^4$ 파라미터, Mouth Regressor $< 10^3$ 수준(은닉 4, 특징 ~ 200 가정). 온디바이스 메모리/연산 부담이 작다.
- **양자화 친화:** 얇은 합성곱/선형 구조로 정적 양자화(INT8) 및 임베디드 변환(ONNX $\rightarrow$ 벤더 툴체인)에 유리.
- **전처리 대체 용이:** 랜드마크/머리자세 모듈은 타 경량 추정기로 교체 가능(플러그형).
- **랜드마크 경량화 전략:** Face Mesh는 정확하지만 무거우므로, (i) ROI+저해상도+프레임 스킵+트래킹, (ii) INT8 양자화, (iii) BlazeFace+소형 랜드마크 헤드(필수 점만), (iv) 68점 또는 그 이하 핵심점 전용 경량 모델 등으로 대체/축소 가능.

7 성능 고찰

7.1 자원 프로파일

- **연산 경량성:** 시선 네트워크 $\sim 7.7 \times 10^4$ 파라미터(≈ 0.31 MB@FP32, 0.08 MB@INT8), 입 회귀 $< 10^3$ 파라미터(< 4 KB@FP32).

- **양자화 이점:** INT8 변환 시 메모리/대역폭 절감, 캐시 적중률 향상으로 지연 감소 기대.
- **지연 분석:** 랜드마크/정규화 + 추론 + 투시/칼만 + I/O(캡처/표시). 추론/전처리가 우세하며 나머지는 경미.

7.2 캘리브레이션 절차

- 화면 네 모서리 순차 제시(수 초): 각 지점에서 시선 샘플 수집, IQR로 이상치 제거 후 평균.
- 대표 4점으로 H (호모그래피) 추정 → 실시간 벡터에 적용해 화면 좌표화.
- 환경(카메라 위치, 사용자 자세, 모니터) 변화 시 재캘리브레이션 권장.

7.3 노이즈/안정화 튜닝

- 프로세스 잡음 $Q \uparrow$: 반응성 증가(빠르게 따라감), 매끄러움 감소. $Q \downarrow$: 반대.
- 측정 잡음 $R \uparrow$: 측정을 덜 신뢰(평활화 증가). $R \downarrow$: 반대. 수집 분산으로 R 초기화 가능.
- 프레임 간 간격 dt 변동은 상태전이 $A(dt)$ 에 반영되어 자연스러운 속도 추정 유지.

8 결론

본 시스템은 얇은 시선 네트워크와 초소형 입 회귀를 조합하고, 4점 투시변환과 칼만 필터로 좌표를 보정해 저전력 엣지 환경에서도 실시간 상호작용을 가능하게 한다. 모델 크기가 작고($\sim 10^4 - 10^3$), 구성요소가 모듈화되어 이식/튜닝이 용이하다.

참고 문헌

- [1] X. Zhang, Y. Sugano, M. Fritz, and A. Bulling, "MPIIGaze: Real-World Dataset and Deep Appearance-Based Gaze Estimation," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 1, pp. 162–175, 2019.
arXiv: arXiv:1711.09017.
- [2] K. Krafcik, A. Khosla, P. Kellnhofer, H. Kannan, S. Bhandarkar, W. Matusik, and A. Torralba, "Eye Tracking for Everyone," in *Proc. CVPR*, 2016.
arXiv: arXiv:1606.05814.
- [3] X. Zhang, Y. Sugano, M. Fritz, and A. Bulling, "Appearance-Based Gaze Estimation in the Wild," in *Proc. CVPR*, 2015.
- [4] X. Zhang, M. Sturman, Y. Sugano, and A. Bulling, "ETH-XGaze: A Large Scale Dataset for Gaze Estimation under Extreme Head Pose and Appearance Variation," in *Proc. ECCV*, 2020.
arXiv: arXiv:2003.09001.
- [5] I. Rakhmatulin and A. T. Duchowski, "Deep Neural Networks for Low-Cost Eye Tracking," *Procedia Computer Science*, vol. 176, pp. 685–694, 2020.
DOI: 10.1016/j.procs.2020.09.041.

- [6] V. Bazarevsky, I. Grishchenko, K. Raveendran, G. Ablavatski, and M. Grundmann, “BlazeFace: Sub-millisecond Neural Face Detection on Mobile GPUs,” 2019.
arXiv: arXiv:1907.05047.
- [7] I. Kartynnik, A. Ablavatski, I. Grishchenko, and M. Grundmann, “Real-time Facial Surface Geometry from Monocular Video on Mobile Devices,” 2019.
arXiv: arXiv:1907.06724.
- [8] V. Lepetit, F. Moreno-Noguer, and P. Fua, “EPnP: An Accurate $O(n)$ Solution to the PnP Problem,” *International Journal of Computer Vision*, vol. 81, pp. 155–166, 2009.
DOI: 10.1007/s11263-008-0152-6.
- [9] R. Hartley and A. Zisserman, *Multiple View Geometry in Computer Vision*, 2nd ed., Cambridge University Press, 2004.
- [10] J. W. Tukey, *Exploratory Data Analysis*, Addison-Wesley, 1977.
- [11] R. Tibshirani, “Regression Shrinkage and Selection via the Lasso,” *Journal of the Royal Statistical Society: Series B*, vol. 58, no. 1, pp. 267–288, 1996.
- [12] J. Friedman, T. Hastie, and R. Tibshirani, “Regularization Paths for Generalized Linear Models via Coordinate Descent,” *Journal of Statistical Software*, vol. 33, no. 1, pp. 1–22, 2010.
URL: jstatsoft.org/article/view/v033i01.
- [13] R. E. Kalman, “A New Approach to Linear Filtering and Prediction Problems,” *Transactions of the ASME—Journal of Basic Engineering*, vol. 82, pp. 35–45, 1960.
- [14] G. Welch and G. Bishop, “An Introduction to the Kalman Filter,” UNC TR 95-041, 2006.
URL: [kalman_intro.pdf](#).